## 爬蟲 Consensus Hong Kong 2025

# 自動化擷取共識大會影片與會議摘要生成系統(全端 SaaS 架構)

## 一、專案概述

本專案致力於實作一個「會議影音資料擷取與自動摘要生成平台」,以 Consensus Hong Kong 2025 為資料來源,建構出完整的資料取得、語音處理、文字摘要與前端展示流程。專案初期應用 Trae AI(付費版)生成前後端框架與初始專案架構,後期則由開發者手動完成邏輯實作與功能整合,並串接 PostgreSQL 資料庫。

#### 專案分為兩大核心模組:

- 1. 音訊擷取模組:自動爬取影片頁面並下載 .aac 音訊
- 2. **摘要生成模組**:將音訊轉為文字後,調用 Gemini LLM 模型生成主旨、重點與結論整體開發採用 GPT-4.0 結合 Trae AI 的開發輔助機制,尤其在 IDE 文件解析、架構解說、生成樣板程式等方面有效提升效率,但摘要邏輯與 API 整合仍以人工 coding 為主,以確保語意正確性與資料一致性。

## 二、第一階段:音訊資料自動擷取模組

#### 2.1 專案目標

實現從共識大會網頁動態抓取影片資訊,解析影片串流地址,並下載音訊檔案,以供後續轉文字與摘要。

#### 2.2 系統架構 (Structure)

模組名稱	功能說明
爬蟲.py	使用 Selenium 自動模擬滑動、展開卡片,擷取活動標題、時間、標籤 與影片連結
get_m3u8_url()	透過 performance API 抓取 .m3u8 串流連結,回傳給主控模組

1_batch_get_url.py	讀取活動清單 CSV,依序解析出每場活動對應的 m3u8 串流網址
2_batch_download_aac.py	使用 ffmpeg 批次下載音訊檔,支援多執行緒下載與失敗重試
src/download_m3u8.py	整合 Selenium Wire,處理 request 資源分析與 cookie 管理

#### 2.3 執行流程(Action)

- 1. 使用 Selenium 開啟網頁,模擬用戶行為展開所有活動資訊。
- 2. 擷取活動標題、連結等資訊並儲存於 csv1.csv 。
- 3. 使用 browser performance API 抓取資源請求紀錄並過濾 .m3u8 連結。
- 4. 統整為資料清單後使用 ffmpeg 無轉碼方式下載音訊,產出 aac 檔案。
- 5. 所有過程自動寫入日誌並處理例外錯誤。

## 2.4 成效(Summary)

- 成功擷取超過 50 條影片對應音訊,平均每支音訊大小約 5-15 MB。
- 建立標準化 CSV 檔案格式,支援後續摘要與語音辨識流程。
- 程式支援中斷續傳與多執行緒加速,符合多場會議批次化處理需求。

## 三、第二階段:會議摘要生成模組

#### 3.1 專案目標

設計一個後端模組,自動讀取逐字稿資料(來源為語音辨識後之轉換結果),並透過 Gemini 大語言模型產出結構化摘要,儲存於資料庫供前端介面查詢使用。

#### 3.2 系統架構 (Structure)

模組名稱	功能說明
generateSummariesWithGemini.js	主摘要模組,從資料庫抓取逐字稿並生成摘要後寫回資料庫
extractSections()	解析 Gemini Markdown 輸出,拆解為主旨(main_idea)、重點(key_points)、結論(conclusion)
uploadData.js	上傳逐字稿至 PostgreSQL
conference_summary 資料表	儲存每場會議對應摘要(欄位包含主旨、重點、結論)
server.js + Express	提供 REST API 給前端應用查詢摘要資料

#### 3.3 執行流程(Action)

- 1. 使用 pg 連接 PostgreSQL,從 conferences 表取得會議逐字稿。
- 2. 呼叫 Gemini API,傳入逐字稿與指定 prompt,回傳摘要 Markdown。
- 3. 將摘要 Markdown 轉為資料庫欄位格式 (main\_idea / key\_points / conclusion)。
- 4. 將結果寫入 conference\_summary 表。
- 5. 提供前端 /api/summary/... API 路徑查詢對應資料。

## 3.4 實作環境與 IDE 工具

- 初始專案架構透過 Trae AI 生成 Express + PostgreSQL 架構。
- 使用 GPT-4.0 對產生的架構解釋與模組描述進行確認與修正。
- 雖然程式碼可初步自動生成,但摘要邏輯(prompt 設計、錯誤處理、資料表關聯) 仍由人工完成,避免語意偏差與資料不一致。

## 3.5 成效(Summary)

- 成功產出數十筆具主旨、重點與結論欄位的摘要資料。
- Gemini 模型生成準確率高於傳統模板匹配式摘要工具,結果清晰可理解。
- 系統已具可擴充性與跨語系摘要應用潛力。

## 四、整合後端 + 前端全端系統(Trae + GPT4 開發歷程)

#### 架構與開發歷程

階段	說明
初始設計	使用 Trae AI 生成 Express + PostgreSQL + API scaffolding 框架
框架解釋與優化	使用 GPT-4 針對每個自動生成模組進行架構解釋與語意調整
核心實作	Gemini API 串接邏輯、摘要處理、資料表關聯,完全手動撰寫
前端介面	基於 HTML/Bootstrap + 原生 JS,接收後端 API 並渲染摘要內容
效率與優勢	GPT-4 解釋文件能力優良,程式生成可加速樣板開發,但實際業務邏輯仍需手寫

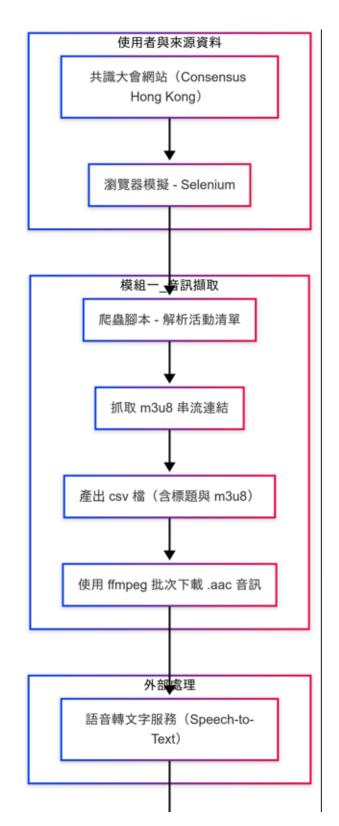
## 五、結論

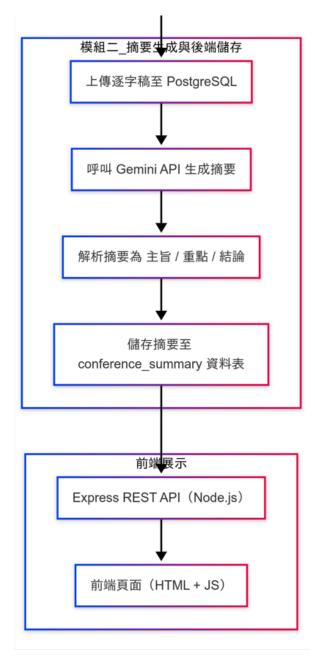
本專案實現一套從國際論壇影片擷取到結構化摘要生成的全端 SaaS 系統,具備:

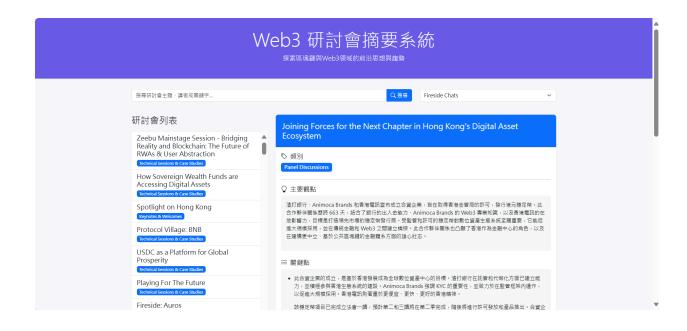
- 1. **自動化處理流程**:從影片網頁  $\rightarrow$  音訊  $\rightarrow$  文字  $\rightarrow$  摘要  $\rightarrow$  前端展示,全程自動化。
- 2. **可維運擴充架構**:採用 PostgreSQL 資料庫與 Express API 結構,便於維運與擴充。
- 3. 生成式 AI 實用導入:Gemini 模型具體落實摘要任務,效能良好。
- 4. **開發效率高**:結合 Trae + GPT4 提升開發效率與系統理解,降低初期建置成本。

整體而言,本專案不僅展示了 AI 技術與自動化流程的結合潛力,也為未來多語系會議資料建檔、企業會議管理、教學影音重整等應用提供實用參考架構。

如需提供系統架構圖(Mermaid / PlantUML)、Swagger API 文件、或部署指令與CI/CD 流程範例,可進一步說明用途,我可持續協助。







爬蟲 Consensus Hong Kong 2025

6